N105

Počítačová laboratoř

1. PATRO · FIT VUT V BRNĚ, BOŽETĚCHOVA 2

Program v této místnosti

8

9

10

11

12

13

14

15

13:00
– 14:00

WORKSHOP

Fact Injections: Bezpečnostní dopady Rank-One Model Editing (ROME) na jazykové modely

Security@FIT

Úprava jediného faktu ve velkém jazykovém modelu obvykle připomíná operaci srdce kladivem. Přetrénování je pomalé a drahé a často naruší chování, které s úpravou vůbec nesouvisí. ROME (Rank-One Model Editing) nabízí chirurgicky přesnější alternativu: s vahami modelu zachází jako s databází, kterou lze aktualizovat přímo na místě. V tomto praktickém workshopu si celou operaci provedete sami. Workshop vychází z probíhajícího výzkumu Red Hatu a FIT VUT v oblasti forenzní analýzy umělé inteligence a krok za krokem vás provede open-source nástrojem: nejprve přepíšeš fakt v modelu jedinou úpravou, poté pacienta vyšetříš, pak si zahraješ na útočníka, který do modelu podstrčí nepravdivý fakt – a nakonec vyzkoušíš prototyp pro detekci upravených modelů.

Naskenuj pro interaktivní mapu a program

1. patro · zde se nacházíš · celý program a mapa fakulty na QR kódu